FleetLogix - Generación de Datos Sintéticos

Descripción del proyecto

FleetLogix es una empresa de transporte y logística que opera una flota de 200 vehículos realizando entregas de última milla en 5 ciudades principales. La empresa ha estado operando con sistemas legacy y hojas de cálculo, pero necesita modernizar su infraestructura de datos para competir en el mercado actual.
El objetivo es potenciar esta infraestructura: poblar todas las tablas con datos sintéticos masivos que respeten las relaciones del negocio, desarrollar queries para resolver problemas operativos reales, y diseñar una arquitectura cloud que permite análisis en tiempo real y toma de decisiones basada en datos.
Como punto de partida, se proporcionó un código base para la generación de datos sintéticos que presentaba funcionalidades incompletas y diversos errores que afectaban la lógica y la consistencia de la información generada. Por esta razón, fue necesario realizar un proceso de análisis, depuración y desarrollo para completar las secciones faltantes, corregir las inconsistencias detectadas y garantizar que los datos generados cumplieran con las relaciones, restricciones y volúmenes requeridos para el proyecto.

Objetivos
El proyecto busca cumplir los siguientes objetivos:

- Analizar el modelo relacional existente.
- Comprender las relaciones entre entidades.
- Generar más de 505.000 registros sintéticos.
- Mantener la integridad referencial.
- Respetar reglas de negocio.
- Validar la calidad de los datos generados.
- Implementar consultas de análisis empresarial.

Tecnologías utilizadas
Durante el desarrollo del proyecto se utilizaron las siguientes herramientas:

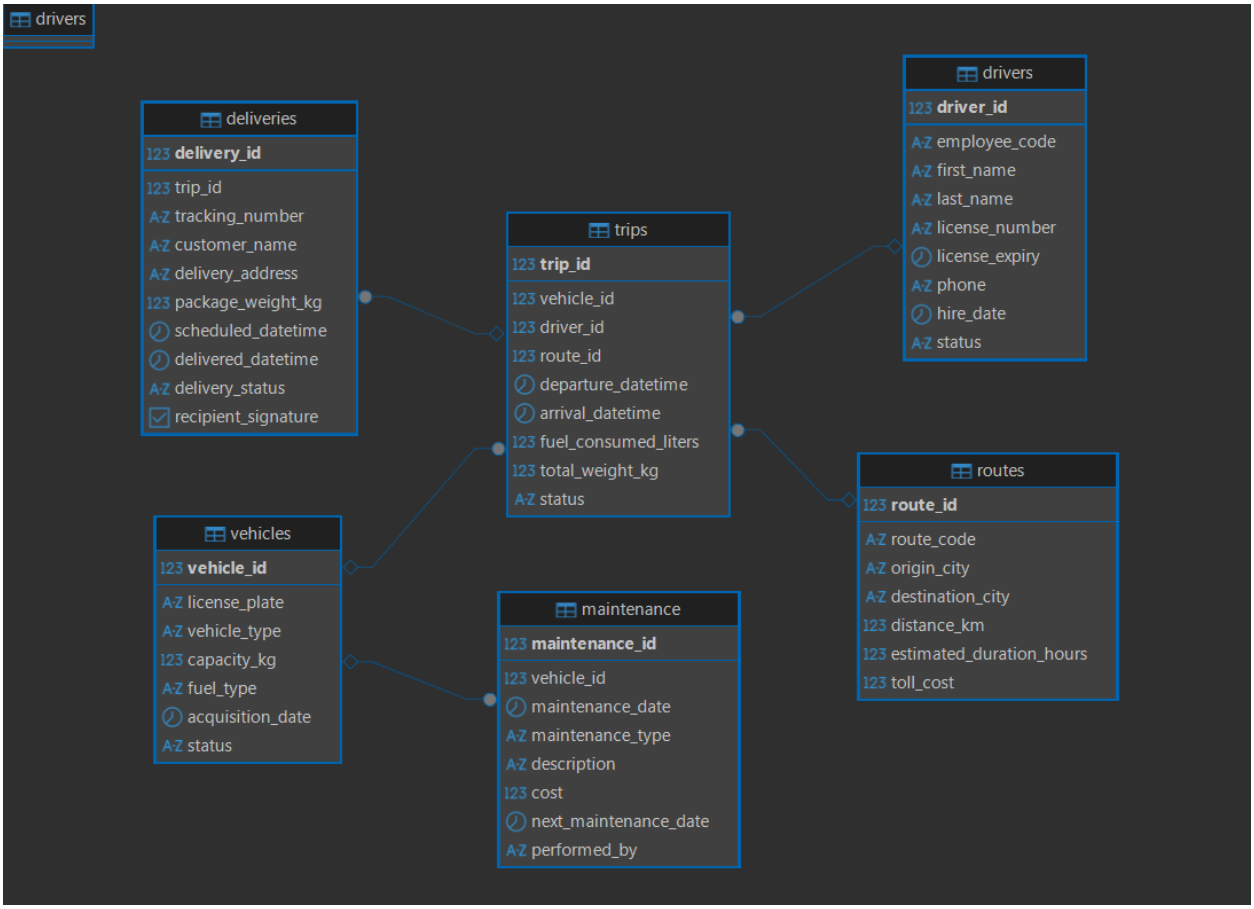
- PostgreSQL 15
- Python 3
- Faker

- NumPy
- Psycopg2
- Pandas
- DBeaver

Modelo de datos
El sistema está compuesto por seis tablas principales:

- Vehicles
- Drivers
- Routes
- Trips
- Deliveries
- Maintenance

Estas entidades representan el funcionamiento de una empresa dedicada al transporte y distribución de mercancías entre diferentes ciudades del país.



Generación de datos sintéticos
Para poblar la base de datos se desarrolló un script en Python completamente automatizado.

La generación se realizó respetando todas las relaciones entre tablas, evitando inconsistencias y simulando un comportamiento cercano a una operación logística real.

Registros generados

Tabla	Registros
Vehicles	200
Drivers	400
Routes	50
Trips	100000
Deliveries	400000
Maintenance	5000

Total: **505.650 registros**

Reglas de negocio implementadas
Durante la generación de datos se respetaron las siguientes reglas:

Vehículos

- Distribución entre camiones grandes, camiones medianos, vans y motocicletas.
- Capacidades diferentes según el tipo de vehículo.
- Fechas de adquisición realistas.
- Vehículos activos y en mantenimiento.

Conductores
Cada conductor posee:

- Código de empleado único.
- Licencia válida.
- Tipo de licencia.
- Fecha de contratación.
- Estado activo o inactivo.

Rutas
Las rutas conectan las principales ciudades de Colombia:

- Bogotá
- Medellín
- Cali
- Barranquilla
- Cartagena

Cada ruta contiene:

- Distancia aproximada.
- Tiempo estimado.
- Valor de peajes.

Viajes
Cada viaje:

- Posee un vehículo existente,
- Posee un conductor existente,
- Pertenece a una ruta válida,
- Respeta la capacidad máxima del vehículo,
- Calcula peso transportado,
- Calcula consumo de combustible,
- Registra fecha de salida y llegada.

Además, los estados fueron distribuidos utilizando probabilidades controladas para simular una operación real.

Entregas
Cada entrega pertenece obligatoriamente a un viaje.
Se generan:

- Cliente,
- Dirección,
- Peso,
- Horario programado,
- Horario real,
- Firma del receptor,
- Estado de la entrega.

La cantidad de entregas por viaje varía entre dos y seis paquetes.

Mantenimientos
Los mantenimientos se generan proporcionalmente al uso de cada vehículo.

Para ello se analizó:

- Cantidad de viajes realizados,
- Periodo de operación,
- Tipo de vehículo.

Esto evita asignar mantenimientos irreales a vehículos poco utilizados.

Control de calidad de datos
Después de generar la información se ejecutó una etapa completa de validación.

Entre las verificaciones realizadas se encuentran:

- Integridad referencial.
- Consistencia temporal.
- Capacidad máxima de carga.
- Consumo de combustible.
- Costos de mantenimiento.
- Distribución estadística de estados.
- Vehículos sin viajes.
- Conductores sin viajes.
- Mantenimientos antes de la compra del vehículo.
- Viajes antes de la contratación del conductor.
- Distribución de entregas.
- Distribución de combustible.
- Duración de viajes.

Estas validaciones permitieron garantizar que los datos fueran consistentes antes de iniciar el análisis.