Construcción del Data Warehouse y Proceso ETL

Con el fin de soportar procesos analíticos y facilitar la toma de decisiones basada en datos, se diseñó e implementó un proceso ETL (Extract, Transform, Load) que permite integrar la información operacional almacenada en PostgreSQL dentro de un Data Warehouse implementado en Snowflake.

El proceso automatiza la extracción de los datos, aplica reglas de transformación y calidad, y carga la información utilizando un modelo dimensional optimizado para consultas analíticas.

Como punto de partida, se proporcionó un código base para la implementación del Data Warehouse en Snowflake que presentaba funcionalidades incompletas y diversos errores que afectaban la carga, transformación y organización de los datos. Por esta razón, fue necesario realizar un proceso de análisis, depuración y desarrollo para completar las secciones faltantes, corregir las inconsistencias detectadas y garantizar que la información fuera cargada correctamente, preservando la integridad de los datos y el funcionamiento adecuado del modelo analítico.

Arquitectura del proceso ETL

El flujo implementado consta de tres etapas principales:

Extracción (Extract)

Se obtiene la información desde la base de datos PostgreSQL a partir de las tablas operacionales:

- Vehicles
- Drivers
- Routes
- Trips
- Deliveries
- Maintenance

Transformación (Transform)

Durante esta etapa se realizaron procesos de limpieza, validación y enriquecimiento de los datos.

Entre las transformaciones implementadas se encuentran:

- cálculo del tiempo real de entrega;
- duración de cada viaje;
- eficiencia de combustible;
- indicadores de puntualidad;
- costos por entrega;
- generación de dimensiones de fecha y hora;
- validación de pesos y tiempos;
- eliminación de registros inconsistentes.

Estas reglas permiten garantizar que únicamente información válida sea cargada al Data Warehouse.

Carga (Load)

Finalmente, la información es cargada en Snowflake mediante procesos automáticos utilizando tablas de staging y operaciones MERGE para mantener actualizadas las dimensiones y la tabla de hechos.

Modelo Dimensional

Se diseñó un esquema estrella (Star Schema) compuesto por una tabla de hechos y múltiples dimensiones.

Tabla de hechos

- FACT_DELIVERIES

Contiene las principales métricas del negocio, incluyendo:

- tiempos de entrega;
- peso transportado;
- consumo de combustible;

- costos;
- indicadores de cumplimiento.

Tablas de dimensiones

- DIM_CUSTOMERS
- DIM_VEHICLES
- DIM_DRIVERS
- DIM_ROUTES
- DIM_DATE
- DIM_TIME

Cada dimensión utiliza claves sustitutas (Surrogate Keys) para facilitar el análisis histórico y mejorar el rendimiento de las consultas.

Calidad de Datos durante el ETL

Antes de realizar la carga al Data Warehouse se aplicaron múltiples validaciones, entre ellas:

- eliminación de tiempos negativos;
- validación de pesos de paquetes;
- consistencia de fechas;
- normalización de tipos de datos;
- control de valores nulos;
- validación de reglas de negocio.

Este proceso permitió garantizar la consistencia de la información analítica.

Automatización del proceso

El proceso ETL fue desarrollado completamente en Python y puede ejecutarse de forma automática.

Durante cada ejecución se registran:

- cantidad de registros extraídos;
- cantidad de registros transformados;
- cantidad de registros cargados;
- tiempo total de ejecución;

- errores encontrados durante el proceso.

Esto facilita el monitoreo y la trazabilidad de la carga de datos.

Validación del Data Warehouse

Una vez finalizada la carga se verificó:

- consistencia de claves sustitutas;
- correspondencia entre dimensiones y tabla de hechos;
- integridad de las relaciones;
- consistencia de métricas calculadas;
- correcto funcionamiento del proceso de carga.

Las pruebas confirmaron que la información almacenada en el Data Warehouse es consistente con los datos operacionales del sistema.